





1 Regresión

Es una forma de aproximar y predecir datos de un fenómeno a partir del estudio de datos existentes (datos históricos). Sin embargo, a diferencia de la interpolación polinomial, las gráficas de las funciones de regresión no contienen, necesariamente, los datos conocidos. Para entender mejor la diferencia, considere el siguiente ejemplo:

Ejemplo: Una empresa que vende calentadores de agua para edificios de apartamentos ha separado su historial en 12 períodos de seis meses cada uno. La empresa sabe cuántas unidades vendió en cada período; dichos datos se muestran en la siguiente tabla:

Período	1	2	3	4	5	6	7	8	9	10	11	12
Unidades vendidas	5	20	19	20	29	35	30	32	40	45	35	50


Solución: Los datos de unidades vendidas por período se visualizan en la figura siguiente, que corresponde a un gráfico de dispersión.



Para estos datos es posible determinar el polinomio interpolante de grado 11, el cual corresponde al polinomio:


$$P_{12}(x) = 3.28179 \times 10^{-5}x^{11} - 0.00233x^{10} + 0.073320x^9 - 1.33098x^8 + 15.4803x^7 - 120.5938x^6 + 639.0213x^5 - 2291.614x^4 + 5420.513x^3 - 8001.902x^2 + 6577.344x - 2231.989$$

La gráfica de este polinomio se muestra en la siguiente figura:



Sin embargo, es posible analizar que el polinomio interpolador no es un buen estimador para algunos datos; por ejemplo, los datos entre el periodo 11 y el 12 muestran un descenso marcado de las imágenes del polinomio. Además, posterior al último periodo se genera un aumento desmesurado de las imágenes del polinomio, por lo que realizar una estimación del periodo 13 sería atrevido e irresponsable, aun cuando sea un periodo cercano a los datos. Esta situación es esperada, se debe recordar que el polinomio interpolante está diseñado para realizar estimaciones de valores entre los datos históricos conocidos y no fuera de ellos.

Por otro lado, se puede observar una dispersión de los datos aproximadamente lineal, así que se puede ajustar una función lineal a los datos históricos. En la figura de abajo se observa la recta mejor ajustada a los datos históricos. Si bien esta no pasa por todos los datos, mantiene información importante, tal como una tendencia creciente de los datos; se denomina línea de tendencia o función de regresión lineal.




La ecuación de la función de regresión lineal mostrada en la figura anterior es

$$y = 3.202x + 9.181,$$

para la cual se tiene que la estimación del trigésimo periodo es 50.8 unidades vendidas.

Ejemplo: La figura de abajo se muestra una gráfica de dispersión de una serie de datos que muestran una tendencia cuadrática. La gráfica de la curva de tendencia cuadrática se muestra posterior en la imagen que le sigue:




4.6.1. Método de mínimos cuadrados

Considere los datos (x_i, y_i) para $i = 1, 2, \dots, n$, se definen dos vectores $\mathbf{x}$ y $\mathbf{y}$ de la siguiente manera:

$$\begin{aligned}\mathbf{x} &= (x_1 \quad x_2 \quad x_3 \quad \cdots \quad x_n) \\ \mathbf{y} &= (y_1 \quad y_2 \quad y_3 \quad \cdots \quad y_n)\end{aligned}$$

Al vector $\mathbf{x}$ se le denomina el vector de causas, mientras que al vector $\mathbf{y}$ se le denomina el vector de efectos. Para poder realizar el proceso de regresión es necesario suponer que es posible explicar el vector $\mathbf{y}$ desde el vector $\mathbf{x}$, y que además están relacionados de forma lineal. De esta manera, la regresión tratará de explicar la relación que existe entre el vector $\mathbf{x}$ y el vector $\mathbf{y}$.



Resumen: Fórmulas de regresión lineal

Para una regresión lineal simple de la forma $y = mx + b$, los coeficientes m y b se calculan mediante las siguientes fórmulas:

$$m = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}$$
$$b = \frac{\sum x_i^2 \sum y_i - \sum x_i \sum x_i y_i}{n \sum x_i^2 - (\sum x_i)^2}$$

También se puede expresar b de forma equivalente como:



$$b = \frac{\sum y_i - m \sum x_i}{n}$$

Ejemplo: Una empresa de tecnología ha registrado sus ingresos anuales (en millones de dólares) durante los últimos ocho años, como se muestra en la siguiente tabla:

x	1	2	3	4	5	6	7	8
y	1.8	2.5	2.9	3.6	4.0	4.8	5.2	5.9

Si la tendencia de crecimiento se mantiene como en los años anteriores, se desea estimar cuáles serán los ingresos proyectados para el noveno año.

Solución:




Ejemplo: Se registra la temperatura del aire a diferentes altitudes en la atmósfera. Los datos obtenidos son los siguientes:

Altitud (km)	0	1	2	3	4	5
Temperatura (°C)	15	8.2	1.5	−5.0	−11.8	−17.0

Se solicita:

- Representar gráficamente los datos en el plano cartesiano.
- Encontrar la recta de mejor ajuste que modele la relación entre la altitud y la temperatura.
- Interpretar el significado de la pendiente de la recta obtenida.

Solución:



4.6.2. Calidad de la representación R^2

Al igual que en todos los métodos de aproximación, es necesario tener una forma de medir la calidad de las aproximaciones. En la mayoría de los casos se realiza mediante el estudio del error; sin embargo, para el caso de la regresión lineal, la calidad se determina por medio del coeficiente de determinación o R^2 .

Definición 1.1: R^2

Sea $\mathbf{x}$ y $\mathbf{y}$ el vector de causas y el vector de efecto, respectivamente, de un modelo de regresión. Y sea $\hat{\mathbf{y}}$ el vector de estimaciones del vector $\mathbf{y}$ por medio de la regresión, entonces se define el **coeficiente de determinación** y se denota R^2 como

$$R^2 = r^2(\hat{\mathbf{y}}, \mathbf{y}) = \frac{\text{var}(\hat{\mathbf{y}})}{\text{var}(\mathbf{y})}$$

donde


$$\text{var}(\mathbf{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \quad \text{con} \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

R^2 : Recibe el nombre de *coeficiente de determinación* y es una medida de la calidad global del conjunto de variables explicativas. Este índice está entre 0 y 1, y representa el porcentaje de la variabilidad de $\mathbf{y}$ que puede ser explicado por las variables de regresión.

Ejemplo: Según datos del Instituto Nacional de Estadística y Censos (INEC), el porcentaje de hogares costarricenses con acceso a internet durante el período 2010-2020 muestra un crecimiento constante. A continuación, se presentan algunos valores:

Año	2010	2012	2014	2016	2018
%hogares con Internet	26	35	45	60	72

- (a) Determine la recta de regresión que modela la relación entre el año y el porcentaje de hogares con acceso a internet.
- (b) Calcule el coeficiente de determinación R^2 y evalúe la calidad del modelo.
- (c) Estime el porcentaje de hogares con acceso a internet en 2020 y proyecte el valor esperado para 2024.



4.6.4. Linealización de datos para regresión

Existen datos a los cuales no se les puede aplicar una regresión lineal simple, pues no siguen un modelo aproximadamente lineal.




Figura 4.16: Modelos no lineales.

Para estos modelos, indudablemente una regresión lineal no responde correctamente a la naturaleza de los datos. Para la figura 4.16(a), un modelo exponencial de la forma $y = \alpha e^{\beta x}$ se adapta mejor a los datos, mientras que en el caso de la figura 4.16(b), un modelo logarítmico de la forma $y = \alpha \ln(\beta x)$, o un modelo de crecimiento de la forma $y = \frac{\alpha x}{\beta + x}$ podría ser más acertado.




Figura 4.17: Modelos no lineales.

- **Modelo exponencial:**




Figura 4.18: Modelo exponencial $y = \alpha e^{\beta x}$

Este modelo tiene la forma $y = \alpha e^{\beta x}$; así, se tienen las siguientes equivalencias:

$$\begin{aligned} y = \alpha e^{\beta x} &\iff \ln(y) = \ln(\alpha e^{\beta x}) \\ &\iff \ln(y) = \ln(\alpha) + \ln(e^{\beta x}) \\ &\iff \ln(y) = \beta x + \ln(\alpha) \end{aligned}$$

de esta manera, el modelo $y = \alpha e^{\beta x}$ se puede ver como un modelo lineal de la forma $Y = \beta x + \ln(\alpha)$, donde $Y = \ln(y)$.

- **Modelo de potencias:**




Figura 4.19: Modelo de potencias $y = \alpha x^{\beta}$

Este modelo tiene la forma $y = \alpha x^{\beta}$; de esta manera se tiene las siguientes equivalencias:

$$\begin{aligned} y = \alpha x^{\beta} &\iff \log(y) = \log(\alpha x^{\beta}) \\ &\iff \log(y) = \log(\alpha) + \log(x^{\beta}) \\ &\iff \log(y) = \beta \log(x) + \log(\alpha) \end{aligned}$$

Así, el modelo $y = \alpha x^\beta$ se puede ver como un modelo lineal de la forma

$$Y = \beta X + \log(\alpha),$$

donde $Y = \log(y)$ y $X = \log(x)$.

• **Modelo de crecimiento:**




Figura 4.19: Figura 4.20: Modelo de crecimiento $y = \frac{\alpha x}{\beta + x}$

Este modelo tiene la forma $y = \frac{\alpha x}{\beta + x}$, donde se tienen las siguientes equivalencias:

$$\begin{aligned} y = \frac{\alpha x}{\beta + x} &\iff \frac{1}{y} = \frac{\beta + x}{\alpha x} \\ &\iff \frac{1}{y} = \frac{\beta}{\alpha x} + \frac{1}{\alpha} \end{aligned}$$

De esta manera, el modelo $y = \frac{\alpha x}{\beta + x}$ se puede ver como un modelo lineal de la forma

$$Y = \frac{\beta}{\alpha} X + \frac{1}{\alpha},$$

donde $Y = \frac{1}{y}$ y $X = \frac{1}{x}$.

Nota importante

Cuando se aplica una transformación a los datos para linealizar un modelo (por ejemplo, utilizando $\ln(y)$ en un modelo exponencial), el coeficiente de determinación R^2 calculado inicialmente corresponde a los datos transformados, es decir, compara $\ln(y)$ real con $\ln(y)$ predicho. Si se desea evaluar la calidad de la predicción en la escala original de y , es necesario revertir la transformación (por ejemplo, aplicando la función exponencial) y comparar los valores de y originales contra los valores predichos. En este caso, el R^2 puede ser diferente al obtenido sobre los datos transformados.

Generalmente, el R^2 sobre los datos transformados tiende a ser ligeramente mayor que el R^2 calculado sobre los datos originales retransformados, aunque si la transformación es adecuada, ambos valores serán muy cercanos.

Ejemplo: Se sabe que los datos de la siguiente tabla se ajustan a un modelo exponencial de la forma:

$$y = \alpha e^{\beta x}$$

donde α y β son parámetros desconocidos a estimar.

Los datos observados son los siguientes:

x	0	1	2	3	4
y	5.0	7.5	11.3	17.0	25.4

Se solicita:

- (a) Transformar adecuadamente la ecuación para linealizar el modelo y aplicar regresión lineal.
- (b) Aplicar regresión lineal directa (sin transformación) a los datos originales.
- (c) Calcular el coeficiente de determinación R^2 en ambos casos y comparar los resultados para evaluar la calidad de los modelos.
- (d) Con base en el mejor modelo, estimar el valor de y para $x = 5$.

Ejemplo: Se sabe que los datos de la tabla siguiente pueden modelarse con la ecuación:

$$y = \alpha \ln(\beta x)$$

donde α y β son parámetros a estimar. Realice una transformación adecuada para linealizar la ecuación anterior y aplique regresión lineal a los datos transformados para determinar los valores de los parámetros α y β . Con base en el modelo obtenido, prediga el valor de y para $x = 6$ y $x = 10$. Además, establezca la calidad de la aproximación calculando el coeficiente de determinación R^2 .

x	1	2	3	4	5
y	2.0	3.8	5.1	5.9	6.5

Tabla: Datos que se ajustan al modelo $y = \alpha \ln(\beta x)$.

Ejemplo: Se sabe que los datos de una tabla pueden modelarse con la ecuación:

$$y = \left(\frac{\alpha + \sqrt{x}}{\beta \sqrt{x}} \right)^2$$

donde α y β son parámetros por estimar.

Realice una transformación adecuada para linealizar la ecuación anterior y exprese el modelo en forma lineal, identificando claramente las nuevas variables dependiente e independiente.